Examen midterm temas selectos de estadística II

Rincon Morales David 418080007 January 11, 2021

Contents

1	Aná	Análisis exploratorio de datos.									
2	Ing	Ingeniería de datos.									
3	Modelo supervisado.										
	3.1	Tabla analítica de datos (TAD)	8								
	3.2	Valores ausentes e imputación	8								
	3.3	Valores extremos	S								
	3.4	Modelación	10								
	3.5	Corriendo los chunks	12								
		3.5.1 Predecir con todos los modelos	12								
	3.6	Persistencia	12								
4	Mo	delo no supervisado.	13								
	4.1	Lectura de datos y limpieza	13								
	4.2	Visualización	13								
		4.2.1 PCA	14								
		4.2.2 MDS	14								
		4.2.3 T-SNE	15								
	4.3	Número de clusters	16								
		4.3.1 Aglomerativo	16								
		4.3.2 K-Means	17								
		4.3.3 Gaussian Mixture	18								
		4.3.4 Visualización 2D T-SNE y Gauss	20								
	4.4	Perfilamiento	20								
	4.5	Ejemplos	20								
5	Estrategia de aplicación de los modelos.										
	5.1	Modelo supervisado:	22								
	5.2	Modelo no supervisado:	22								
	5.3	Nota	22								
6	Cor	nclusiones.	23								
7	Anexos.										

1 Análisis exploratorio de datos.

Al ser una base de datos sumamente extensa se tuvieron problemas de RAM por falta de memoria, a lo cual para poder hacer el tratamiento y análisis exploratorio de los datos, se hizo una división por "chunks" con 1M (millón) de registros en cada uno. En el caso del modelo supervisado, sólo se elijieron variables que nos ayudaran a predecir el volumen de rides por hora (pickup), las cuales son: Lectura de datos

Data Reading

Select specific columns to save memory and processing power

Figure 1: Lectura de datos

Una vez que ya tenemos nuestras variables, se leyó el archivo "csv", asignando los tipos de datos correspondientes para así poder evitar mayor uso de memoria RAM.

Como estamos usando el dataset por "chunk", elegimos utilizar el primero para así poder analizar y procesar la información. Revisamos si no tenemos datos faltantes: Datos faltantes

No missing data, no need to worry. We next filter the data for 2018.

Figure 2: Check for null variables

No tenemos datos faltantes, por lo que se procede a limpiar información que no necesitamos. Al manejar datasets por particiones, debemos hacer todos los cálculos por funciones, por lo que nuestra primer función es: data_filter

```
[4]: def data_filter(df):
         ''' data_filter
         Filters data where:
             -Data is not from 2018
             -Total amount is less than zero
             -Passenger count is less than one
             -Trip distance is less or equal to zero
             -Drop passenger_count (we dont use it later in the model)
         Parameter
         df: Dataframe chunk
         #Filters data not from 2018
         start_date = pd.to_datetime('2018-01-01 00:00:00')
         end date = pd.to datetime('2019-01-01 00:00:00')
         mask = (df['tpep_pickup_datetime'] >= start_date) & (df['tpep_pickup_datetime'] < end_date)</pre>
         df = df.loc[mask]
         #Filters data where total amount is less than zero
         df = df[df["total amount"] > 0.00]
         #Filters where passenger count is less than one
         df = df[df["passenger_count"] >= 1]
         #Filters where trip distance = 0
         df = df[df["trip_distance"] > 0]
         df.drop(['passenger_count'], axis=1, inplace = True)
         return df
```

Figure 3: Data filter function

Luego pasamos por otra función llamada "dates", la cual hace split de la columna "tpep_pickup_time" y la convierte en dos columnas; además, agrega "pickup_hour" para posteriormente hacer un catálogo de horas. Finalmente, corremos nuestro chunk de datos por una función llamada "hours_catalog" la cual nos regresa la columna "id hour". hours catalog

Hours Catalog

```
def hours_catalog(df):
    '''hours_catalog

Creates id_hour (int16) column based on pickup_hour sorted column

Parameter
    ......

df: Chunk of Dataframe that contains pickup_hour values:
    First two values: Month number
    Third and Fourth values: Day of the week {01: Monday .... 07:Sunday}
    Last two values: Hour

'''

catfh = df[['pickup_hour']].drop_duplicates().sort_values('pickup_hour', ascending=True).reset_index(drop=True)
    catfh["id_hour"] = (catfh.index+1)
    catfh["id_hour"] = catfh["id_hour"].astype('int16')

df = df.merge(catfh, on='pickup_hour', how='inner')
    df.drop('pickup_hour', axis=1, inplace=True)

return df
```

Figure 4: Función para catálogo de horas

2 Ingeniería de datos.

Una vez que ya pasamos por el proceso anterior y creamos nuestro catálogo de horas "id_hour", obtenemos el primer y último valor de esa columna para poder definir hora_inicial y hora_final. Luego definimos nuestra ventana de observación, la ventana de desempeño y nuestras anclas.

Además, definimos nuestra unidad muestral, nuestro step y nuestras variables continuas y discretas. variables

Data Engineering

```
[17]: horai,horaf = df[['id_hour']].describe().T[['min','max']].values[0].tolist()
horai,horaf

[17]: (1.0, 134.0)

[18]: vobs = 24
   vdes = 1
   anclai = int(horai)+vobs-1
   anclaf = int(horaf)-vdes
   anclai,anclaf

[18]: (24, 133)

[19]: um = ['PULocationID', 'ancla']
   ancla = 24
   step = 4
   varc = ['trip_distance', 'total_amount', 'n']
   vard = ['hora']
```

Figure 5: Horas, Anclas y Steps

Posteriormente, pasamos a una función donde nos regrese un dataframe compuesto por todas variedades de nuestras variables, por ejemplo: trans

```
CPU times: user 4min 58s, sys: 2.82 s, total: 5min 1s Wall time: 5min 1s
[21]: X_test.head()
                                                                PULocation ID \quad v\_hora\_min\_n\_3\_4 \quad v\_hora\_min\_n\_total\_hora\_4 \quad v\_hora\_min\_total\_amount\_3\_4 \quad v\_hora\_min\_total\_amount\_total\_hora\_4 \quad v\_hora\_min\_total\_amount\_total\_hora\_4 \quad v\_hora\_min\_total\_hora\_4 \quad v
                                                                                                                                    1
                                                                                                                                                                                                                                                  1.0
                                                                                                                                                                                                                                                                                                                                                                                                                           1.0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  105.30
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               105.30
                                             0
                                             1
                                                                                                                                                                                                                                                  1.0
                                                                                                                                                                                                                                                                                                                                                                                                                         1.0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             5.80
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        5.80
                                             2
                                                                                                                                                                                                                                                     1.0
                                                                                                                                                                                                                                                                                                                                                                                                                             1.0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             4.80
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          4.80
                                                                                                                              10
                                                                                                                                                                                                                                                    1.0
                                                                                                                                                                                                                                                                                                                                                                                                                             1.0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         35.38
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    35.38
                                                                                                                                  12
                                                                                                                                                                                                                                                     1.0
```

Figure 6: Función trans

Después de tener X listo, creamos Y para luego proceder a la modelación: y



Figure 7: Creación de Y

3 Modelo supervisado.

3.1 Tabla analítica de datos (TAD).

Cuando ya tenemos Nuestras dos tablas X, Y, vamos a correr la función "TAD", la cual hace un merge entre estas dos tablas sobre la unidad muestral. tad

Creación de TAD (Tabla analítica de datos) $\vec{y} = f(\mathcal{X})$

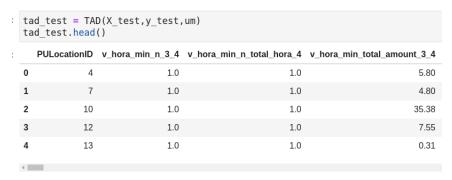


Figure 8: TAD

3.2 Valores ausentes e imputación

Luego de haber conseguido la TAD, nos aseguramos si hay valores ausentes en ella. Si hay valores ausentes en TAD, pasamos por una función "impute" la cual nos va a regresar dos variables: imputar

Impute

```
def impute(tad, varc):
    '''impute

    Returns
    X: Based on TAD column with only columns from varc list
    Xi: Imputed df based on X with median strategy

Parameters
    ......
    tad: TAD table
    varc: list of continued variables
    '''

    X = tad[varc].copy()
    im = SimpleImputer(strategy='median')
    im.fit(X)
    Xtrans = im.transform(X)

    Xi = pd.DataFrame(Xtrans, columns=varc)

#Kolmogorov-Smirnov (Two distributions are statistically equal)
    ks = pd.DataFrame(map(lambda v: (v,ks_2samp(tad[v].dropna(),Xi[v]).statistic),varc),columns=['variable','ks'])
    print(ks.loc[ks['ks']>.1])
    return X, Xi
```

Figure 9: Imputación

3.3 Valores extremos.

Para poder cuantificar todos nuestros valores extremos, pasamos nuestro dataset, unidad muestra y TAD a nuestra función "extreme" la cual nos imprimirá la cantidad de valores extremos en nuestro chunk de datos. extremos

Valores Extremos

```
[27]: extreme(X_test, um, tad_test)
      count
               9585.000000
      mean
                  0.509442
      std
                  0.499937
                  0.000000
      min
      25%
                  0.000000
      50%
                  1.000000
      75%
                  1.000000
                  1.000000
      max
      Name: extremo, dtype: float64
```

Figure 10: Valores extremos

Como podemos dar cuenta, la cantidad de valores extremos representa un 0.95% de nuestro chunk.

3.4 Modelación.

Cuando hayamos conseguido nuestra tabla Xi (imputada), podemos seguir con nuestro modelo. Para ello pasamos a nuestra función "regression" la cual necesita los parámetros (tad, tgt, Xi).

En esta función vamos a hacer un split de nuestro chunk entre "train" y "test" para luego buscar los mejores hiperparámetros a través de "GridSearchCV" y para ello ya podemos hacer fit de nuestros datos.

Para poder verificar nuestro modelo, se imprimen los mean absolute error, primero con los valores de entrenamiento y después los valores para testing: mean errors

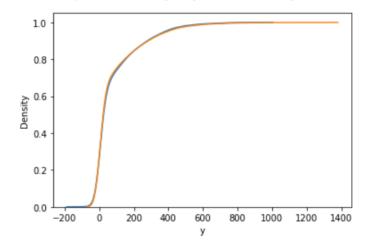
```
[34]: print(mean_absolute_error(y_true=yt_test,y_pred=modelo_test.predict(Xt_test)))
print(mean_absolute_error(y_true=yv_test,y_pred=modelo_test.predict(Xv_test)))
22.515774748259656
22.701732484535974
```

Figure 11: Mean absolute error

Otra forma de ver la funcionalidad de nuestro modelo, es con las siguientes gráficas. La primer gráfica es con datos de training y la segunda con datos de testing: graficas

```
[35]: sns.distplot(modelo_test.predict(Xt_test), hist=False, kde_kws={'cumulative':True})
sns.distplot(yt_test, hist=False, kde_kws={'cumulative':True})
```

[35]: <AxesSubplot:xlabel='y', ylabel='Density'>



```
sns.distplot(modelo_test.predict(Xv_test), hist=False, kde_kws={'cumulative':True})
sns.distplot(yv_test, hist=False, kde_kws={'cumulative':True})
```

[36]: <AxesSubplot:xlabel='y', ylabel='Density'>

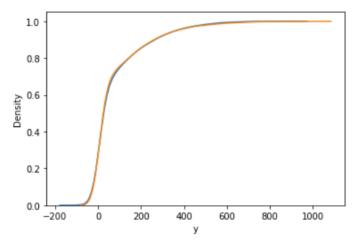


Figure 12: Gráficas del modelo

3.5 Corriendo los chunks

Al inicio de esta sección, se comentó que se usaron funciones al correr el proceso y, al momento de decirle a pandas que usaremos chunks, este nos regresa un iterador, el cual podemos usar en un for y así correr todos los modelos y haciendo append a una lista.

3.5.1 Predecir con todos los modelos

En estas ocaciones de modelado, lo ideal es usar la media de las predicciones de todos los modelos y así tener un resultado óptimo.

3.6 Persistencia

Ya que este es un modelado bastante pesado computacionalmente, lo ideal es que guardemos todos los modelos de nuestros chunks, para eso usaremos la librería "pickle" de la siguiente forma: pickle

```
[40]: import pickle

[45]: with open("models_other.pkl", "wb") as f:
    for model in models:
        pickle.dump(model, f)
```

Si queremos abrir los modelos de nuevo para evitar entrenamiento

```
[42]: new_models = []
with open("models.pckl", "rb") as f:
    while True:
        try:
            new_models.append(pickle.load(f))
        except EOFError:
            break
[44]: len(new_models)
[44]: 112
```

Figure 13: Persistencia modelo supervisado

Lo que estamos haciendo aquí, es guardar todos los modelos de nuestra lista en un mismo archivo. Si luego queremos leer esos modelos, simplemente los guardamos en una lista.

4 Modelo no supervisado.

4.1 Lectura de datos y limpieza.

En el caso del modelo no supervisado usamos la librería "Dask" de computación paralela al leer nuestro dataset y limpiarlo más eficiente. Similar a nuestro modelo supervisado, pasamos las variable que vayamos a utilizar para el clustering: lectura

Figure 14: Lectura de datos modelo no supervisado

Una vez leído nuestro "dask dataframe" hacemos una descripción para datos ilógicos y procedemos a limpiarlos. filtro

```
[4]: temp = temp[temp['passenger_count'] > 0]
  temp = temp[temp['passenger_count'] < 7]
  temp = temp[temp['trip_distance'] > 0]
  temp = temp[temp['total_amount'] > 0]
```

Figure 15: Limpieza datos modelo no supervisado

4.2 Visualización.

Después de haber filtrado los datos, sacamos una muestra de nuestra información y lo convertimos a un dataframe de pandas, luego seleccionamos nuestras variables continuas y procedemos con el procesamiento.

4.2.1 PCA

Para las variables que seleccionamos, y al hacer un "Standard Scaler", obtenemos una explicación de la varianza del 74% en dos dimensiones. $\rm pca$

Figure 16: PCA

4.2.2 MDS

mds

Figure 17: MDS

En MDS no podemos ver algún cluster con claridad

4.2.3 T-SNE

tsne

T-SNE

Figure 18: T-SNE

En T-SNE podemos ver un poco mejor algunos clusters

4.3 Número de clusters

Luego de haber visto la reducción de dimensiones y el análisis de correlaciones, pasamos a ver una gráfica de "codo" para determinar cuántos clusters haremos. codo

[18]: [<matplotlib.lines.Line2D at 0x7f5768fc6240>]

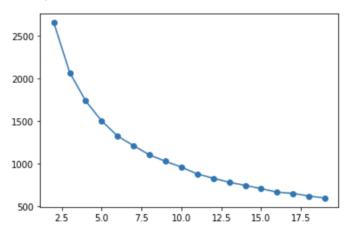


Figure 19: Gráfica de "codo"

En este caso vamos a tomar de referencia 7 clusters

4.3.1 Aglomerativo

Los porcentajes en este algoritmo son: aglomerativo

```
0 0.052761
1 0.360736
2 0.020859
3 0.134969
4 0.139877
5 0.160736
6 0.130061
Name: agg, dtype: float64
```

[21]: <AxesSubplot:ylabel='agg'>

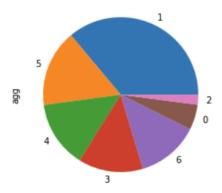


Figure 20: Aglomerativo

4.3.2 K-Means

Porcenyajes en K-Mean: k-means

```
0 0.166871
1 0.195092
2 0.285890
3 0.022086
4 0.072393
5 0.236810
6 0.020859
Name: kme, dtype: float64
```

[22]: <AxesSubplot:ylabel='kme'>

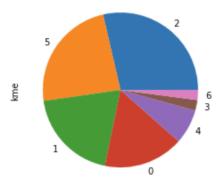


Figure 21: K-Means

4.3.3 Gaussian Mixture

Como podemos ver, la mezcla Gaussiana nos da una mejor distribución en el cluster $\,$ gauss

```
0 0.159509
1 0.050307
2 0.269939
3 0.132515
4 0.169325
5 0.107975
6 0.110429
Name: gau, dtype: float64
```

[23]: <AxesSubplot:ylabel='gau'>

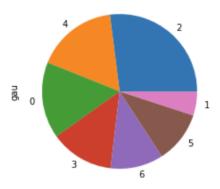


Figure 22: Gaussiana

4.3.4 Visualización 2D T-SNE y Gauss

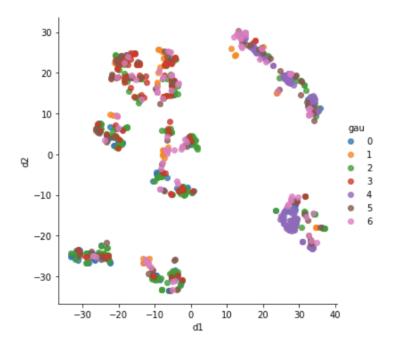


Figure 23: T-SNE con Gauss

En la figura anterior podemos observar que, aunque los clusters están mezclados, algunos colores dominan, en el lado derecho se puede aprecuar un dominio del cluster 4 mientras que en la esquina inferior izquierda hay más cluster 2

4.4 Perfilamiento.

Para poder verificar qué variables nos son más útiles para hacer clustering, debemos hacer un perfilamiento considerando el p-value. Una forma alternativa es usando el método "SelectKBest", el cual nos dice que todas nuestras variables son significativas.

4.5 Ejemplos.

Para observar nuestro clustering, podemos hacer lo siguiente: ejemplos

```
[64]: k = 5
      cl = 2
      for id in df.loc[df['gau']==cl].sample(k).D0LocationID:
          print(id)
      140
      142
      246
      224
      238
[69]: i = 5
      cluster = 4
      for id in df.loc[df['gau']==cluster].sample(i).trip_distance:
          print(id)
      0.699999988079071
      1.2999999523162842
      0.4699999988079071
      0.6000000238418579
      0.49000000953674316
```

Figure 24: Ejemplos modelo no supervisado

5 Estrategia de aplicación de los modelos.

Algunas propuestas para hacer uso de estos modelos son:

5.1 Modelo supervisado:

- 1. Predicción de demanda general y/o por zona: Al tener como base la locación donde se tomó el taxi, podemos generalizar para todo Nueva York o para una zona en específico. Además de mejorar costos al reducir el número de taxis dependiendo la hora del día.
- 2. Predicción taxis disponible: Con una pequeña modificación, podemos predecir cuántos taxis se liberan cada hora para así poder mover a los taxis a las zonas con mayor tráfico de clientes.

5.2 Modelo no supervisado:

- Clusterización de zonas: Podemos hacer clusters de qué zonas son las que toman viajes más largos/cortos, las zonas con ticket promedio más alto. Y haciendo una combinación con el modelo supervisado, optimizar recursos para obtener mayores ingresos.
- 2. Clusters con mayor número de pasajeros: Con una modificación podríamos arreglar este algoritmo para mover carros más grandes a zonas donde los viajes tienen más ocupantes.

5.3 Nota.

En ambos modelos, las propuestas se pueden implementar de diferentes formas, ya sea que se predija con un servicio cloud a una aplicación web ó podemos exportar los modelos y hacer un dashboard para que equipos de business development tomen las mejores decisiones.

6 Conclusiones.

Al hacer este tipo de proyectos, se debe tener muy en cuenta toda la ingeniería de datos; ya que, si no la hacemos de la forma correcta nuestros modelos serán erroneos y no generalizarán. Por otro lado es interesante ver cómo se desarrolla el backend de muchas de las aplicaciones que usamos en la vida cotidiana en las cuales existen algoritmos de recomendación, mejor ruta, etc.

Una alternativa para el modelo supervisado sería probar con el algoritmo de redes neuronales y ver la diferencia de eficiencia comparado con regresión lineal. Además indagar en otras formas de procesamiento de la información; ya que, con chunks es bastante tardado debido a que pandas sólo utiliza un núcleo del procesador, tres posibles soluciones son: pasar la información a una base de datos SQL (aprovechando nuestras funciones), sacando una muestra para así ahorrarnos poder de cómputo ó finalmente usando la librería "Dask" de cómputo paralelo para poder procesar la información.

7 Anexos.

Los anexo con los códigos en Jupyter empiezan en la siguiente página.

Linear Model

Libraries

```
import pandas as pd
In [1]:
         import numpy as np
         import os
         from functools import reduce
         from datetime import date, datetime
         from scipy.stats import ks_2samp
         from sklearn.preprocessing import StandardScaler
         from sklearn.impute import SimpleImputer
         from sklearn.linear_model import LinearRegression
         from sklearn.metrics import mean_absolute_error
         from sklearn.metrics import roc_auc_score,accuracy_score
         from sklearn.model_selection import train_test_split
         from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
         import matplotlib.pyplot as plt
         import seaborn as sns
         import pygal
         from scikitplot.metrics import plot_roc_curve
         import warnings
         warnings.filterwarnings('ignore')
         %matplotlib inline
         pd.set_option('display.max_columns',500)
```

Data Reading

Select specific columns to save memory and processing power

Functions

Data Filter

```
In [4]:
         def data filter(df):
             ''' data_filter
             Filters data where:
                 -Data is not from 2018
                 -Total amount is less than zero
                 -Passenger count is less than one
                 -Trip distance is less or equal to zero
                 -Drop passenger_count (we dont use it later in the model)
             Parameter
             _ _ _ _ _ _ _ _ _
             df: Dataframe chunk
             #Filters data not from 2018
             start_date = pd.to_datetime('2018-01-01 00:00:00')
             end_date = pd.to_datetime('2019-01-01 00:00:00')
             mask = (df['tpep_pickup_datetime'] >= start_date) & (df['tpep_pickup_datetim']
             df = df.loc[mask]
             #Filters data where total amount is less than zero
             df = df[df["total_amount"] > 0.00]
             #Filters where passenger count is less than one
             df = df[df["passenger_count"] >= 1]
             #Filters where trip distance = 0
             df = df[df["trip_distance"] > 0]
             df.drop(['passenger_count'], axis=1, inplace = True)
             return df
In [5]:
         def dates(df):
             '''dates
             Splits Datetime into two new columns:
                 -pickup_date
                 -pickup_hour
             Adds column:
                 -pickup_hour where: First two digits represent month,
                                      Middle two represent day of the week
                                      Last two represent the pickup hour
             Drops the original datetime column
             Parameter
             df: Dataframe chunk
             df['pickup_date'] = df['tpep_pickup_datetime'].dt.date
```

df['pickup_time'] = df['tpep_pickup_datetime'].dt.time
df['pickup_time'] = df['pickup_time'].astype(str)

Hours Catalog

```
In [6]:
         def hours_catalog(df):
              '''hours_catalog
              Creates id_hour (int16) column based on pickup_hour sorted column
              Parameter
              df: Chunk of Dataframe that contains pickup_hour values:
                  First two values: Month number
                  Third and Fourth values: Day of the week {01: Monday .... 07:Sunday}
                  Last two values: Hour
              \mathbf{I}_{-}\mathbf{I}_{-}\mathbf{I}_{-}
              catfh = df[['pickup_hour']].drop_duplicates().sort_values('pickup_hour',asce
              catfh["id_hour"] = (catfh.index+1)
              catfh["id_hour"] = catfh["id_hour"].astype('int16')
              df = df.merge(catfh, on='pickup_hour', how='inner')
              df.drop('pickup_hour', axis=1, inplace=True)
              return df
```

Data Engineering

```
In [7]: def trans(df,ancla,k):
    '''trans

Parameters
------
df: Chunk of Dataframe
ancla: current ancla to run
k: current step
'''

aux = df.loc[(df['id_hour']>=(ancla-k+1))&(df['id_hour']<=ancla)].reset_inde
aux = aux[['id_hour', 'trip_distance', 'total_amount', 'pickup_time','PULoca
aux['hora'] = aux['pickup_time'].map(lambda x:int(x.split(':')[0])//6).astyp
aux.drop('pickup_time',axis=1,inplace=True)
aux['n'] = 1</pre>
```

TAD & Target

Impute

```
In [10]:
          def impute(tad, varc):
               '''impute
              X: Based on TAD column with only columns from varc list
              Xi: Imputed df based on X with median strategy
              Parameters
               . . . . . . . . . .
              tad: TAD table
              varc: list of continued variables
               1.1.1
              X = tad[varc].copy()
              im = SimpleImputer(strategy='median')
              im.fit(X)
              Xtrans = im.transform(X)
              Xi = pd.DataFrame(Xtrans, columns=varc)
              #Kolmogorov-Smirnov (Two distributions are statistically equal)
              ks = pd.DataFrame(map(lambda v: (v,ks_2samp(tad[v].dropna(),Xi[v]).statistic
              print(ks.loc[ks['ks']>.1])
```

```
return X, Xi
```

Extreme Values

```
In [11]: def extremo(df,v,ci,cs):
    aux = df[um+[v]].copy()
    aux['ol_%s'%v] = ((aux[v]<ci)|(aux[v]>cs)).astype(int)
    return aux.drop(v,axis=1)

def extreme(X, um, tad):
    cotas = X.describe(percentiles=[0.01,0.99]).T[['1%', '99%']].reset_index().v
    ext = reduce(lambda x,y:pd.merge(x,y,on=um,how='outer'),map(lambda z:extremo varol = [v for v in ext if v[:2]=='ol']
    ext['extremo'] = ext[varol].max(axis=1)
    print(ext['extremo'].describe())
```

Modelling (Find parameters $ec{ heta}$ of model f for

$$ec{y} = f(\mathcal{X})
ightarrow y = heta_0 + ec{ heta} \cdot ec{x}$$

```
def regression(tad, tgt, Xi):
In [12]:
               '''regression
               Creates a linear model for the df passed.
               Appends the model to the models list so we can dump it with pickle
               Parameters
               _ _ _ _ _ _ _ _ _ _
               tad: TAD table for the dataframe chunk
               tgt: target column
               Xi: table with imputed values
               1.1.1
               y = tad[tgt].copy()
               Xt, Xv, yt, yv = train_test_split(Xi, y, train_size=0.7)
               modelo = LinearRegression()
               hiperparametros=dict(fit_intercept=[True, False], normalize=[True, False])
               grid = GridSearchCV(param_grid=hiperparametros,
                                estimator=modelo,
                                cv=10,
                                scoring='neg_mean_absolute_error',
                                n_{jobs}=-1,
                                verbose=True)
               grid.fit(Xt,yt)
               modelo = grid.best_estimator_
               modelo.fit(Xt,yt)
               modelo.intercept_
               print(mean_absolute_error(y_true=yt,y_pred=modelo.predict(Xt)))
               print(mean_absolute_error(y_true=yv,y_pred=modelo.predict(Xv)))
               Xv['y^{\prime}] = modelo.predict(Xv)
```

```
Xv['y'] = yv
modelo.coef_
models.append(modelo)
```

First Chunk

Get the first chunk of data to test our functions

```
In [13]:
          %%time
          df = iterator.get_chunk()
          CPU times: user 1min 18s, sys: 26.2 ms, total: 1min 18s
          Wall time: 1min 19s
          df.isnull().sum()
In [14]:
Out[14]: VendorID
                                    0
          tpep_pickup_datetime
                                    0
          passenger_count
                                    0
          trip distance
                                    0
          PULocationID
                                    0
          payment_type
                                    0
          total_amount
                                    0
          dtype: int64
         No missing data, no need to worry. We next filter the data for 2018.
```

CPU times: user 11.6 s, sys: 318 ms, total: 11.9 s Wall time: 11.9 s

Hours Catalog

Out[16]:		VendorID	trip_distance	PULocationID	payment_type	total_amount	pickup_date	pickup_time	id_l
	0	2	8.00	230	2	26.80	2018-09-22	23:46:37	
	1	2	1.70	141	1	11.76	2018-09-22	23:00:43	
	2	2	3.84	163	2	15.30	2018-09-22	23:10:32	
	3	2	1.80	166	2	9.80	2018-09-22	23:27:25	
	4	2	2.43	229	1	13.30	2018-09-22	23:50:39	
	4								•

Data Engineering

```
In [17]: horai,horaf = df[['id_hour']].describe().T[['min','max']].values[0].tolist()
horai,horaf
Out[17]: (1.0, 134.0)
```

```
In [18]:
                                  vobs = 24
                                   vdes = 1
                                   anclai = int(horai)+vobs-1
                                  anclaf = int(horaf)-vdes
                                  anclai, anclaf
Out[18]: (24, 133)
                                  um = ['PULocationID', 'ancla']
In [19]:
                                   ancla = 24
                                   step = 4
                                   varc = ['trip_distance', 'total_amount', 'n']
                                   vard = ['hora']
In [20]:
                                  %%time
                                  X_{test} = pd.concat(map(lambda ancla:reduce(lambda x,y:pd.merge(x,y,on=um,how='ou'))
                                                          map(lambda k:trans(df,ancla,k),range(step,vobs+step,step))),range(anclai,
                                CPU times: user 4min 58s, sys: 2.82 s, total: 5min 1s
                               Wall time: 5min 1s
In [21]:
                                 X_test.head()
Out[21]:
                                        PULocationID v_hora_min_n_3_4 v_hora_min_n_total_hora_4 v_hora_min_total_amount_3_4 v_hora_min_total_hora_4 v_hora_min_total_amount_3_4 v_hora_min_total_hora_4 v_hora_min_total_hora_4 v_hora_min_total_hora_5 v_hora_min_total_hora_6 v_hora_min_total_hora_7 v_hora_min_total_hora_8 v_hora_8 v_
                                0
                                                                        1
                                                                                                                        1.0
                                                                                                                                                                                                    1.0
                                                                                                                                                                                                                                                                              105.30
                                1
                                                                        4
                                                                                                                                                                                                                                                                                    5.80
                                                                                                                        1.0
                                                                                                                                                                                                    1.0
                                2
                                                                        7
                                                                                                                                                                                                                                                                                    4.80
                                                                                                                        1.0
                                                                                                                                                                                                    1.0
                                                                                                                                                                                                                                                                                 35.38
                                                                     10
                                                                                                                         1.0
                                                                                                                                                                                                    1.0
                                                                     12
                                                                                                                         1.0
                                                                                                                                                                                                    1.0
                                                                                                                                                                                                                                                                                    7.55
                                  y_test= pd.concat(map(lambda ancla: target(df,ancla,vdes),range(anclai,anclaf+1)
In [22]:
                                  y_test.head()
                                         PULocationID
                                                                                   y ancla
Out[22]:
                                0
                                                                                   7
                                                                                                   24
                                1
                                                                        7
                                                                                21
                                                                                                   24
                                                                     10
                                                                                   6
                                                                                                   24
                                                                     12
                                                                                   1
                                                                                                   24
                                                                     13 27
                                                                                                   24
                             TAD (Tabla analítica de datos) ec{y} = f(\mathcal{X})
```

	PULocationID	v_hora_min_n_3_4	v_hora_min_n_total_hora_4	v_hora_min_total_amount_3_4	v_hora
2	10	1.0	1.0	35.38	
3	12	1.0	1.0	7.55	
4	13	1.0	1.0	0.31	
4					•

Exploratory Analysis

Variable Selection

```
In [24]: varc_test = [v for v in tad_test.columns if v[:2]=="v_"]
tgt_test = 'y'
```

Missing Values Counting

```
In [46]: miss_test = 1-tad_test[varc_test].describe().T[['count']]/len(tad_test)
    miss_test.describe()
```

```
count
Out[46]:
            count 450.000000
                     0.293301
            mean
              std
                     0.224234
                     0.000000
             min
             25%
                     0.113302
             50%
                     0.231716
             75%
                     0.467293
             max
                     0.736255
```

Impute

```
In [26]:
          X_test, Xi_test = impute(tad_test, varc_test)
                                   variable
                                                   ks
               v_hora_min_total_amount_3_4
                                             0.329459
              v_hora_min_trip_distance_3_4
                                             0.345802
               v_hora_max_total_amount_3_4
                                             0.345092
              v_hora_max_trip_distance_3_4
                                             0.346276
              v_hora_mean_total_amount_3_4
         14
                                             0.346986
         444
                           v_hora_sum_n_2_4
                                             0.328851
         445
               v_hora_sum_total_amount_2_4
                                             0.328851
         446
              v_hora_sum_trip_distance_2_4
                                             0.328851
         448
               v_hora_std_total_amount_2_4
                                             0.344966
              v_hora_std_trip_distance_2_4
         449
                                             0.344966
         [181 rows x 2 columns]
```

Valores Extremos

```
In [27]: extreme(X_test, um, tad_test)
```

```
count
         9585.000000
mean
             0.509442
             0.499937
std
min
             0.00000
             0.000000
25%
50%
             1.000000
75%
             1.000000
             1.000000
max
Name: extremo, dtype: float64
```

Modelación (encontrar los parámetros $ec{ heta}$ del modelo f para $ec{y}=f(\mathcal{X}) o y= heta_0+ec{ heta}\cdotec{x}$

```
tad_test.head()
In [28]:
Out[28]:
            PULocationID v_hora_min_n_3_4 v_hora_min_n_total_hora_4 v_hora_min_total_amount_3_4 v_hora
          0
                      4
                                     1.0
                                                             1.0
                                                                                     5.80
          1
                      7
                                     1.0
                                                             1.0
                                                                                     4.80
                     10
          2
                                     1.0
                                                             1.0
                                                                                     35.38
          3
                     12
                                                                                     7.55
                                     1.0
                                                             1.0
                                                                                     0.31
                     13
                                     1.0
                                                             1.0
In [29]:
          y_test = tad_test['y'].copy()
          Xt_test, Xv_test, yt_test, yv_test = train_test_split(Xi_test, y_test, train_size=0.7
          modelo_test = LinearRegression()
          hiperparametros=dict(fit_intercept=[True, False], normalize=[True, False])
           grid_test = GridSearchCV(param_grid=hiperparametros,
                           estimator=modelo_test,
                           cv=10,
                            scoring='neg_mean_absolute_error',
                           n_{jobs=-1}
                           verbose=True)
          grid_test.fit(Xt_test,yt_test)
In [30]:
          Fitting 10 folds for each of 4 candidates, totalling 40 fits
          [Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
          [Parallel(n_jobs=-1)]: Done 40 out of 40 | elapsed:
                                                                      7.7s finished
Out[30]: GridSearchCV(cv=10, estimator=LinearRegression(), n_jobs=-1,
                       param_grid={'fit_intercept': [True, False],
                                     'normalize': [True, False]},
                       scoring='neg_mean_absolute_error', verbose=True)
          modelo_test = grid_test.best_estimator_
In [31]:
          modelo_test.fit(Xt_test,yt_test)
In [32]:
         LinearRegression(fit_intercept=False, normalize=True)
Out[32]:
          modelo_test.intercept_
In [33]:
```

```
Out[33]: 0.0
In [34]:
          print(mean_absolute_error(y_true=yt_test,y_pred=modelo_test.predict(Xt_test)))
          print(mean_absolute_error(y_true=yv_test,y_pred=modelo_test.predict(Xv_test)))
          22.515774748259656
          22.701732484535974
          sns.distplot(modelo_test.predict(Xt_test), hist=False, kde_kws={'cumulative':True}
In [35]:
          sns.distplot(yt_test, hist=False, kde_kws={'cumulative':True})
Out[35]: <AxesSubplot:xlabel='y', ylabel='Density'>
            1.0
            0.8
            0.6
            0.4
            0.2
            0.0
                          200
               -200
                                400
                                     600
                                          800
                                               1000
                                                    1200
                                                         1400
                                     у
          sns.distplot(modelo_test.predict(Xv_test), hist=False, kde_kws={'cumulative':True}
In [36]:
          sns.distplot(yv_test, hist=False, kde_kws={'cumulative':True})
Out[36]: <AxesSubplot:xlabel='y', ylabel='Density'>
            1.0
            0.8
            0.6
            0.4
            0.2
            0.0
               -200
                            200
                                   400
                                          600
                                                800
                                                      1000
In [37]:
          Xv_test['y^'] = modelo_test.predict(Xv_test)
          Xv_test['y'] = yv_test
In [38]:
          modelo_test.coef_
         array([-1.48760393e-01, -1.48760393e-01,
                                                      1.33688497e-01, -8.21227846e-01,
                 -1.80719876e-01,
                                    1.03225620e+00, -1.48760393e-01, -1.48760393e-01,
```

```
3.47944646e-01, -1.04221773e-03, -1.30113183e+00, -4.62142203e-03,
-1.48760393e-01, -1.48760393e-01, 2.49133424e-02, 7.01695131e-01,
-7.00091044e-01, -8.87602136e-02, -1.24168639e+00,
                                                    1.17520706e+00,
1.25832842e-02,
                 2.84669706e-02,
                                  3.69635076e-01, -5.15159571e-01,
1.14446785e-11, -1.80533366e-12, -7.77923529e-01, -7.69044832e-01,
2.89467352e+00,
                1.30259978e-01, -1.48760393e-01, -1.48760393e-01,
-1.48760393e-01,
                 1.07424143e+00, 5.39737947e-01, -3.65926858e-01,
                                  1.29557904e+00, -1.48760393e-01
-5.71023681e-01, -2.96726946e+00,
-1.48760393e-01, -1.48760393e-01,
                                  -4.76540925e-01, -1.75090748e-01,
                 1.09945962e+00,
                                   1.09507451e+00, -9.74702102e-01,
2.93042754e-01,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -7.57862669e-01,
-7.88799788e-01, -1.52582439e-02, -1.28742316e+00,
                                                   2.97879228e+00
2.75856969e-01, -1.70366949e+00, -1.33331046e+00,
                                                   1.45210675e+00
7.35876946e-02,
                 3.09158991e-02, -5.04361851e-02,
                                                   1.00563833e-01,
2.19445916e-01, -1.41264099e-01, -1.61537450e-14, -1.33920652e-13,
9.45493683e-14,
                 1.89428444e+00,
                                  8.11460776e-01, -5.57794434e-01,
-3.36485940e+00, -3.24264437e+00,
                                  1.94858723e+00, -1.48760393e-01,
-1.48760393e-01, -1.48760393e-01, -1.22439797e-01, -9.20638780e-01,
-4.29445645e-01, -1.84611341e+00,
                                  4.41350368e+00,
                                                    1.44743570e+00,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
                                                   3.17672330e-02
                                  2.20882601e-01,
                                                  -6.91002117e-01
1.37878153e-01, -1.32618603e-01,
-2.05031525e-02, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
1.13389600e-01, 8.67916863e-01, 5.64349997e-01,
                                                   2.75574543e+00
-3.32265811e+00, -1.58444104e+00,
                                   2.08273892e+00,
                                                   2.18622092e+00,
                1.10005306e-01,
-2.02852314e+00,
                                   1.05868640e-01, -1.22938339e-01,
-1.24074186e+00, -1.23515380e+00,
                                   1.28288192e+00, -8.54871729e-14,
-1.13242749e-14, -4.32986980e-14, -7.15690269e-01, -7.86635339e-01,
3.68908113e-02,
                 2.34001202e+00,
                                  3.99790013e+00,
                                                   -8.48601770e-01
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
-1.17033693e-01, -3.50870627e-01,
                                  1.07519623e-01,
                                                   5.33245394e-01,
-6.34462692e-01,
                 1.06644777e+00,
                                  6.06055298e-01, -1.69160828e+00,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
-2.33149899e-02,
                 2.14080413e-01, -4.45045130e-02, -2.67635320e-02,
4.76397650e-01,
                                   5.40700948e-01, -9.24102899e-01,
                 6.29695696e-01,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
3.16897603e-01, -1.41349375e-02, -1.90821221e-01, -2.53143358e-01,
-1.99790477e+00, -1.08691507e+00, -1.57045496e+00,
                                                   2.78054243e+00
2.66365062e+00,
                 2.65850481e+00, 2.66739894e+00, -2.65055484e+00,
-8.80118936e-02, -8.24347544e-02, -1.10679953e-01, 8.67703212e-02,
-4.03816320e-01, -4.31824601e-01, -3.14663990e-01,
                                                    3.96437487e-01,
-3.17523785e-14,
                1.62092562e-14, -2.98649994e-14,
                                                    2.17603713e-14,
-3.79441557e-01, -7.12657867e-01,
                                   1.79564622e-01,
                                                    7.61302476e-01,
2.62448112e-01, -8.98544562e-01,
                                  9.45667919e-02,
                                                  -4.62498233e-01
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
-1.48760393e-01, -3.69573799e-01, -4.13698407e-01,
                                                   1.13239005e+00,
-2.45156342e-01, -5.44315796e-01,
                                  9.49376652e-01,
                                                   1.69307493e+00,
-4.70068902e+00, -9.38987518e-01,
                                  2.91975550e+00, -1.48760393e-01,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
                 2.11426621e-01, -1.84120913e-01, -1.62264554e-02,
-1.10542426e-01,
8.07796667e-02,
                 7.63924785e-01, -1.33127957e+00, -1.41430534e+00,
                 1.43765357e+00, -1.48760393e-01, -1.48760393e-01,
-1.08195940e+00,
                                                   2.53777735e-01
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
6.11569094e-02, -9.08936296e-01,
                                   1.15865762e-01,
                                                   4.37881421e-01,
-4.85943772e-01,
                 6.73858664e-01,
                                   7.44649012e+00,
                                                    2.98742216e+00,
-6.81289537e+00, -1.37684477e+00,
                                  -1.64640277e+00, -1.56546075e+00,
-1.81046231e+00,
                 1.44055825e+00,
                                   1.13495202e-01,
                                                    1.21187129e-01,
1.35991214e-01,
                 1.77801935e-01, -1.17284849e-01, -9.53549904e-02,
-1.19104619e-01, -1.64111090e-01, -3.02896808e-01,
                                                   1.11545796e-01
                                  1.26565425e-14,
5.80091530e-15, -1.33226763e-15,
                                                  -5.32907052e-15
6.69603262e-15, -1.71111043e-02, -4.31129795e-01,
                                                   8.54122193e-01,
-2.04420416e-01, -5.79524192e-01, -6.89687791e-01,
                                                   2.52517627e+00,
-1.33413629e+00, -9.11990196e-02,
                                  8.68699261e-01, -1.48760393e-01,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
-2.68845444e-01, -4.30198881e-01, -8.09855452e-01, 5.15595154e-01,
3.71544952e-01,
                 2.29458350e+00,
                                   2.46001943e+00,
                                                    4.05058079e+00,
```

```
-1.50003270e+00, -2.84399717e+00, -1.48760393e-01, -1.48760393e-01,
-1.48760393e-01, -1.48760393e-01, -1.48760393e-01, 7.03519969e-03,
                1.98796634e-01, -3.07641675e-02, -1.08718149e-01,
-7.25624041e-02,
-3.99784656e-01, -1.23347457e-01, 2.61781404e-01, 6.70140867e-01,
-1.70499938e-01, -1.48760393e-01, -1.48760393e-01, -1.48760393e-01,
-1.48760393e-01, -1.48760393e-01, 5.86854001e-01, 4.22347144e-01,
6.62088394e-01, -1.86258510e-01, -4.58021734e-01, -3.24426286e+00,
-2.56458123e+00, -5.96989635e+00, -2.53422546e-01, 5.30742409e+00,
5.05152213e-01, 5.78096564e-01, 3.89240524e-01, 6.26597780e-01,
-3.50714541e-01, -9.69596369e-02, -9.48210783e-02, -8.78706361e-02,
-1.15754293e-01, 8.14079268e-02, 3.33510099e-01, 3.70735829e-01,
3.19555166e-01,
                 4.19383341e-01, -3.08197800e-01, -8.88178420e-16,
0.0000000e+00,
                 3.10862447e-15, -3.77475828e-15, -1.33226763e-15,
-1.99070463e-01,
                 1.25050175e-01, -5.04444050e-01,
                                                  5.06474401e-01,
3.82348449e-02,
                2.19918105e+00,
                                 1.19021973e+00, 1.61582891e+00,
-2.16726845e+00, -8.94120871e-01, -1.48760393e-01,
                                                  9.33433484e-01,
-2.46596863e+00, -1.48760393e-01, -4.43811363e-01,
                                                   5.91878118e-01,
-1.48760393e-01, -1.14077106e+00, 2.18176411e+00, -2.34762466e+00,
1.65298362e-01, -8.15424772e-02,
                                 0.0000000e+00,
                                                   1.16371907e+00
1.35341950e-01, -1.48760393e-01, -1.94399739e-02,
                                                   2.39253097e+00
                                 8.85652794e-01,
-1.48760393e-01, 8.96549189e-02,
                                                  -1.48760393e-01
1.38956986e-01, -3.21611261e+00, -1.15765211e+00,
                                                  1.69119867e-03,
3.05248060e-01, 0.000000000e+00, -2.71598848e-01, 1.88633632e+00,
-1.48760393e-01, -1.36075873e-01, -3.31376252e+00, -1.48760393e-01,
-6.35789860e-02, 1.34656102e+00, -1.48760393e-01, 2.50974719e-01,
2.69207013e+00, 2.31366120e+00,
                                  1.00786138e-01, -1.25805647e+00,
0.00000000e+00, 1.72419164e-01, -5.60703566e+00, -1.48760393e-01,
7.79090694e-01, -1.00211327e+00, -1.48760393e-01, 1.73270799e-01,
                                                  2.04440461e+00.
-1.38140334e+00, -1.48760393e-01, -1.15770623e+00,
2.16136467e+00, -2.87131010e-02, -5.52172746e-01, 0.000000000e+00,
7.53421935e-02, 2.47762726e+00, -1.48760393e-01, 8.44966709e-01,
7.30641236e-01, -1.48760393e-01, 4.05826464e-03, -3.63405248e-02,
-1.48760393e-01, -7.38617825e-01, -1.53793510e+00, -8.27014282e-01,
-3.97980927e-02, 5.59548517e-01, 0.00000000e+00,
                                                   7.26728373e-01,
1.23617094e+00, -1.48760393e-01,
                                  8.36611784e-01, -4.70918669e+00
-1.48760393e-01, -2.49362165e-01,
                                 9.43478171e-01, -1.48760393e-01,
-7.02875995e-01, 5.00561668e+00, -1.57273582e+00,
                                                  4.92869140e-02,
1.77723583e-01,
                0.00000000e+00, 8.96051179e-01, -5.01175561e+00,
-1.48760393e-01, 2.65063958e-01, -3.83080933e-01, -1.48760393e-01,
5.09553565e-02, 8.35719221e-01, -1.48760393e-01, -2.39717421e-01,
-4.79719337e-01, 2.12053206e+00,
                                  1.27340988e-01, -1.32746825e+00,
0.00000000e+00, -8.11836185e-02, -5.24474048e-02, -1.48760393e-01,
                7.88814318e-02, -1.48760393e-01,
                                                   1.65148631e-01,
3.24389840e-01,
-4.13702407e-01, -1.48760393e-01, -1.30164145e-01, -1.14939492e+00,
-6.19870349e-01, -6.10749375e-02, 6.09387869e-01, 0.00000000e+00,
2.40205003e-01, 4.95726094e-01])
```

Juntamos todas las funciones para predecir con todos los chunks

```
hri,hrf = chunk[['id_hour']].describe().T[['min', 'max']].values[0].tolist()
    vobs = 24
    vdes = 1
    anclai = int(hri)+vobs-1
    anclaf = int(hrf)-vdes
    um = ['PULocationID', 'ancla']
    ancla = 24
    step = 4
    varc = ['trip_distance', 'total_amount', 'n']
    vard = ['hora']
    print(f'Hra inicial: {hri}, Modelo: {number}')
    print(f'Hra final: {hrf}, Modelo: {number}')
    X = pd.concat(map(lambda ancla:reduce(lambda x,y:pd.merge(x,y,on=um,how='out)
            map(lambda k:trans(chunk,ancla,k),range(step,vobs+step,step))),range(
    y= pd.concat(map(lambda ancla: target(chunk,ancla,vdes),range(anclai,anclaf+
    tad = TAD(X, y, um)
    varc = [v for v in tad.columns if v[:2]=="v_"]
     tgt = 'y'
    miss = 1-tad[varc].describe().T[['count']]/len(tad)
    X, Xi = impute(tad, varc)
    extreme(X, um, tad)
    regression(tad, tgt, Xi)
    number += 1
Model number 1
Hra inicial: 1.0, Modelo: 1
Hra final: 112.0, Modelo: 1
                         variable
                                         ks
      v_hora_min_total_amount_1_4 0.294406
4
      v_hora_min_total_amount_2_4 0.316723
6
     v_hora_min_trip_distance_1_4 0.312624
7
     v_hora_min_trip_distance_2_4
                                   0.323951
12
      v_hora_max_total_amount_1_4
                                   0.312452
444
                 v_hora_sum_n_0_8 0.266582
445
      v_hora_sum_total_amount_0_8 0.266818
446
     v_hora_sum_trip_distance_0_8 0.266700
448
      v_hora_std_total_amount_0_8 0.288464
449
     v_hora_std_trip_distance_0_8
                                   0.288464
[156 rows x 2 columns]
         9722.000000
count
mean
            0.358465
            0.479574
std
            0.00000
min
25%
            0.000000
50%
            0.00000
75%
            1.000000
            1.000000
Name: extremo, dtype: float64
Fitting 10 folds for each of 4 candidates, totalling 40 fits
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done 40 out of 40 | elapsed:
                                                          3.9s finished
```

```
14
     v_hora_mean_total_amount_0_4
                                    0.345952
444
                 v_hora_sum_n_3_4
                                    0.341100
445
      v_hora_sum_total_amount_3_4
                                    0.341568
446
     v hora sum trip distance 3 4
                                    0.341568
448
      v_hora_std_total_amount_3_4
                                    0.351450
449
     v_hora_std_trip_distance_3_4
                                    0.351450
[164 rows x 2 columns]
count
         9209.000000
mean
            0.404061
std
            0.490736
min
            0.00000
25%
            0.00000
            0.00000
50%
75%
            1.000000
            1.000000
max
Name: extremo, dtype: float64
Fitting 10 folds for each of 4 candidates, totalling 40 fits
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done 40 out of 40 | elapsed:
                                                           2.9s finished
18.75571170775452
20.830105257517218
Model number 112
Hra inicial: 1.0, Modelo: 112
Hra final: 30.0, Modelo: 112
                            variable
                                            ks
3
        v_hora_min_total_amount_2_4
                                      0.195548
6
       v_hora_min_trip_distance_2_4
                                      0.225138
12
        v_hora_max_total_amount_2_4
                                      0.225138
15
       v_hora_max_trip_distance_2_4
                                      0.225138
21
       v_hora_mean_total_amount_2_4
                                      0.225138
24
      v_hora_mean_trip_distance_2_4
                                      0.225138
27
                                      0.225138
                    v hora sum n 2 4
30
        v_hora_sum_total_amount_2_4
                                      0.225138
33
       v_hora_sum_trip_distance_2_4
                                      0.225138
39
        v_hora_std_total_amount_2_4
                                      0.249995
42
       v_hora_std_trip_distance_2_4
                                      0.249995
49
        v_hora_min_total_amount_1_8
                                      0.385702
53
       v_hora_min_trip_distance_1_8
                                      0.409316
61
        v_hora_max_total_amount_1_8
                                      0.417187
                                      0.417187
65
       v_hora_max_trip_distance_1_8
73
       v_hora_mean_total_amount_1_8
                                      0.417187
77
      v_hora_mean_trip_distance_1_8
                                      0.417187
81
                    v_hora_sum_n_1_8
                                      0.417187
85
        v_hora_sum_total_amount_1_8
                                      0.417187
89
                                      0.417187
       v_hora_sum_trip_distance_1_8
97
        v_hora_std_total_amount_1_8
                                      0.422749
101
       v_hora_std_trip_distance_1_8
                                      0.422749
170
       v_hora_min_total_amount_0_16
                                      0.231921
175
      v_hora_min_trip_distance_0_16
                                      0.237683
185
       v_hora_max_total_amount_0_16
                                      0.237683
190
      v_hora_max_trip_distance_0_16
                                      0.239123
200
      v_hora_mean_total_amount_0_16
                                      0.239123
205
     v_hora_mean_trip_distance_0_16
                                      0.239123
210
                  v_hora_sum_n_0_16
                                      0.239123
215
       v hora sum total amount 0 16
                                      0.239123
220
      v_hora_sum_trip_distance_0_16
                                      0.239123
230
                                      0.275000
       v_hora_std_total_amount_0_16
235
      v_hora_std_trip_distance_0_16
                                      0.275000
         640.000000
count
mean
           0.325000
           0.468741
std
min
           0.00000
           0.000000
25%
```

```
0.000000
75% 1.000000
max 1.000000
Name: extremo, dtype: float64
Fitting 10 folds for each of 4 candidates, totalling 40 fits
[Parallel(n_jobs=-1)]: Using backend LokyBackend with 12 concurrent workers.
[Parallel(n_jobs=-1)]: Done 40 out of 40 | elapsed: 0.2s finished 15.399852347320953
38.200627576156414
CPU times: user 7h 51min 52s, sys: 5min 39s, total: 7h 57min 32s
Wall time: 7h 52min 21s
```

Persistencia de los Modelos

```
In [40]: import pickle
In [45]: with open("models_other.pkl", "wb") as f:
    for model in models:
        pickle.dump(model, f)
```

Si queremos abrir los modelos de nuevo para evitar entrenamiento

Anexo Modelo No Supervisado

January 11, 2021

1 Clustering Model

1.1 Libraries

```
[1]: import pandas as pd
  import dask.dataframe as dd
  import numpy as np
  import random

from sklearn.preprocessing import StandardScaler,MinMaxScaler
  from sklearn.decomposition import PCA
  from sklearn.manifold import TSNE,MDS
  from sklearn.cluster import AgglomerativeClustering,KMeans
  from sklearn.mixture import GaussianMixture

from scipy.stats import kruskal

from sklearn.feature_selection import SelectKBest

import matplotlib.pyplot as plt
  import seaborn as sns
```

1.2 Data Loading

```
[78]: temp.describe(percentiles=(0.01,0.99)).compute().T[['min','1%','99%','max']]
[78]:
                                       1%
                                                   99%
                                min
                                                                  max
                                      1.0
      passenger_count
                        -64.000000
                                              6.000000
                                                            96.00000
      trip_distance
                          0.000000
                                      0.2
                                            19.629999
                                                        189483.84375
      PULocationID
                          1.000000
                                     13.0
                                           264.000000
                                                           265.00000
      DOLocationID
                          1.000000
                                     13.0
                                           264.000000
                                                           265.00000
      tip_amount
                       -322.500000
                                      0.0
                                            13.046875
                                                           946.00000
      total_amount
                       -800.299988
                                      4.8
                                            75.669998
                                                        907071.06250
     1.2.1 Vamos a predecir el numero de pasajeros.
     Tiramos los que tengan 0, 7,8 y 9 pasajeros
 [4]: temp = temp[temp['passenger_count'] > 0]
      temp = temp[temp['passenger_count'] < 7]</pre>
      temp = temp[temp['trip_distance'] > 0]
      temp = temp[temp['total_amount'] > 0]
 [5]:
     df = temp.sample(frac=0.000008).compute()
 [6]:
      df.describe()
 [6]:
                                                                             tip_amount
             passenger_count
                                trip_distance
                                               PULocationID
                                                              DOLocationID
                   815.000000
                                                  815.000000
                                                                             815.000000
      count
                                   815.000000
                                                                 815.000000
      mean
                     1.592638
                                     2.939276
                                                  161.150920
                                                                 157.980368
                                                                                1.917969
      std
                     1.205412
                                     3.818235
                                                   67.278825
                                                                  71.961135
                                                                                2.480469
      min
                     1.000000
                                     0.070000
                                                    4.000000
                                                                   1.000000
                                                                               0.000000
      25%
                     1.000000
                                     0.920000
                                                  113.000000
                                                                 107.000000
                                                                               0.000000
      50%
                     1.000000
                                     1.570000
                                                  162.000000
                                                                 162.000000
                                                                                1.450195
      75%
                     2.000000
                                     3.110000
                                                  233.000000
                                                                 233.000000
                                                                                2.455078
                     6.000000
                                    34.900002
                                                  264.000000
                                                                 265.000000
      max
                                                                               25.546875
             total_amount
               815.000000
      count
      mean
                 16.325069
                 13.937790
      std
      min
                  3.300000
      25%
                  8.300000
      50%
                 11.800000
      75%
                 18.299999
      max
                153.350006
```

[7]: df.describe(percentiles=[0.001, 0.01, 0.99]).T[['0.1%', '1%', '99%']]

```
[7]:
                        0.1%
                                1%
                                           99%
    passenger_count 1.00000
                               1.0
                                      6.000000
    trip_distance
                     0.09442
                               0.3
                                     18.647400
    PULocationID
                     6.44200 13.0 264.000000
    DOLocationID
                     1.00000
                               7.0 264.000000
    tip_amount
                     0.00000
                               0.0
                                     11.703125
    total_amount
                     3.70700
                               4.8
                                     69.197600
```

1.3 Visualization

```
[8]: varc = [v for v in df.columns if v != "passenger_count"]
varc
```

[8]: ['trip_distance', 'PULocationID', 'DOLocationID', 'tip_amount', 'total_amount']

```
[9]: X = df[varc].copy()
```

1.3.1 PCA

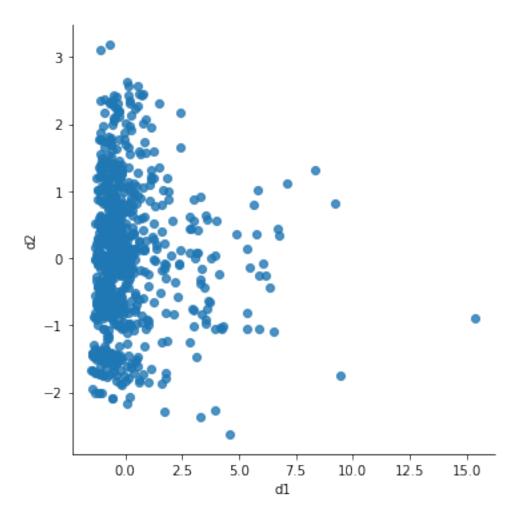
```
[10]: sc = StandardScaler()
    sc.fit(X)
    Xs = pd.DataFrame(sc.transform(X),columns=varc)
    pca = PCA(n_components=2)
    pca.fit(Xs)
    pca.explained_variance_ratio_.cumsum()
```

[10]: array([0.5179963 , 0.74349976], dtype=float32)

```
[11]: Xp = pd.DataFrame(pca.transform(Xs),columns=['d1','d2'])
```

```
[12]: sns.lmplot(data=Xp,x='d1',y='d2',fit_reg=False)
```

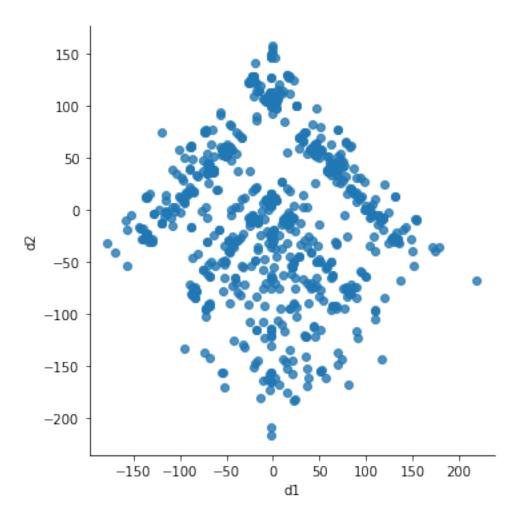
[12]: <seaborn.axisgrid.FacetGrid at 0x7f574c407550>



1.3.2 MDS

```
[13]: mds = MDS(n_components=2,n_jobs=-1)
Xm = pd.DataFrame(mds.fit_transform(X),columns=['d1','d2'])
sns.lmplot(data=Xm,x='d1',y='d2',fit_reg=False)
```

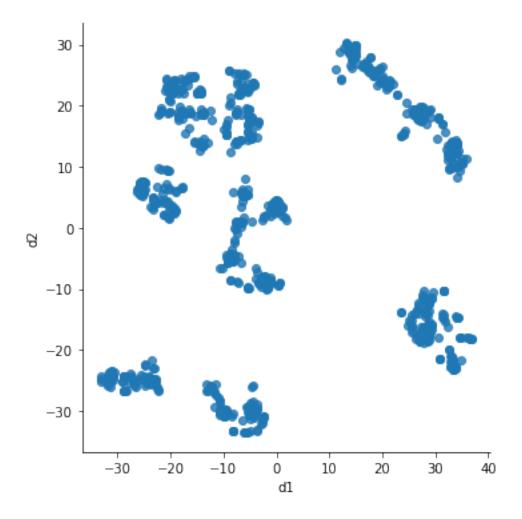
[13]: <seaborn.axisgrid.FacetGrid at 0x7f574c3175f8>



1.3.3 T-SNE

```
[14]: tsne = TSNE(n_components=2,n_jobs=-1)
Xt = pd.DataFrame(tsne.fit_transform(X),columns=['d1','d2'])
sns.lmplot(data=Xt,x='d1',y='d2',fit_reg=False)
```

[14]: <seaborn.axisgrid.FacetGrid at 0x7f574c2dfa58>



1.4 Exploratory Analysis

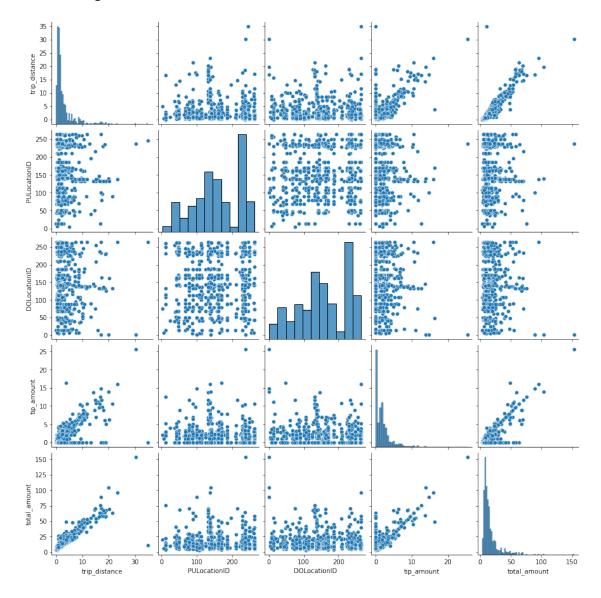
[15]:	<pre>X.describe(percentiles=np.arange(0,1,0.1))</pre>
-------	---

[15]:	trip_distance	PULocationID	${\tt DOLocationID}$	tip_amount	total_amount
cour	t 815.000000	815.000000	815.000000	815.000000	815.000000
mean	2.939276	161.150920	157.980368	1.917969	16.325069
std	3.818235	67.278825	71.961135	2.480469	13.937790
min	0.070000	4.000000	1.000000	0.000000	3.300000
0%	0.070000	4.000000	1.000000	0.000000	3.300000
10%	0.600000	68.000000	48.000000	0.000000	6.368000
20%	0.818000	100.000000	87.000000	0.000000	7.850000
30%	1.040000	132.000000	125.000000	0.000000	8.800000
40%	1.296000	141.000000	142.000000	1.000000	10.300000
50%	1.570000	162.000000	162.000000	1.450195	11.800000
60%	1.918000	170.000000	170.000000	1.781641	13.800000

70%	2.600000	230.000000	230.000000	2.160156	16.000000
80%	3.700000	236.000000	236.000000	2.951563	20.768000
90%	7.108000	239.000000	241.400000	4.558594	32.016000
max	34.900002	264.000000	265.000000	25.546875	153.350006

[16]: sns.pairplot(X)

[16]: <seaborn.axisgrid.PairGrid at 0x7f574c2c6d68>



[17]: X.corr()

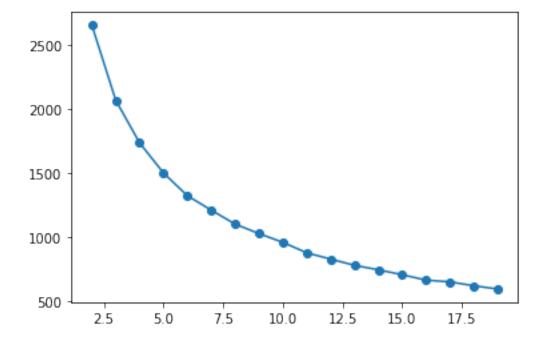
[17]: trip_distance PULocationID DOLocationID tip_amount \ trip_distance 1.000000 -0.034582 -0.089966 0.644051

```
PULocationID
                    -0.034582
                                    1.000000
                                                  0.141475
                                                              -0.020398
DOLocationID
                    -0.089966
                                    0.141475
                                                   1.000000
                                                              -0.061298
tip_amount
                     0.644051
                                   -0.020398
                                                  -0.061298
                                                               1.000000
total_amount
                     0.907124
                                   -0.039812
                                                  -0.112205
                                                               0.799711
                total_amount
                    0.907124
trip_distance
{\tt PULocationID}
                   -0.039812
DOLocationID
                   -0.112205
tip_amount
                    0.799711
total_amount
                    1.000000
```

1.4.1 # of Clusters

```
[18]: l = []
for k in range(2,20):
        cl = KMeans(n_clusters=k)
        cl.fit(Xs)
        l.append(cl.inertia_)
plt.plot(range(2,20),l,marker='o')
```

[18]: [<matplotlib.lines.Line2D at 0x7f5768fc6240>]



```
[19]: k = 7
```

```
[20]: varc = X.columns.tolist()
varc
```

[20]: ['trip_distance', 'PULocationID', 'DOLocationID', 'tip_amount', 'total_amount']

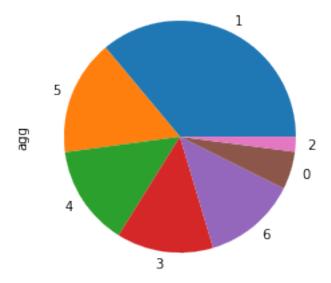
1.5 Modelo no supervisado (Aglomerativo)

```
[21]: cl = 'agg'
    agg = AgglomerativeClustering(n_clusters=k)
    X[cl]=Xs[cl]=Xm[cl]=Xt[cl]=Xp[cl]=df[cl] = agg.fit_predict(Xs[varc])
    display(df[cl].value_counts(True).sort_index())
    df[cl].value_counts().plot(kind='pie')
```

- 0 0.052761
- 1 0.360736
- 2 0.020859
- 3 0.134969
- 4 0.139877
- 5 0.160736
- 6 0.130061

Name: agg, dtype: float64

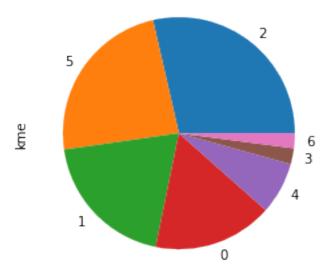
[21]: <AxesSubplot:ylabel='agg'>



1.6 K-Means

[22]: <AxesSubplot:ylabel='kme'>

```
[22]: cl = 'kme'
      agg = KMeans(n_clusters=k)
      X[cl]=Xs[cl]=Xm[cl]=Xt[cl]=Xp[cl]=df[cl] = agg.fit_predict(Xs[varc])
      display(df[cl].value_counts(True).sort_index())
      df[cl].value_counts().plot(kind='pie')
     0
          0.166871
          0.195092
     1
     2
          0.285890
     3
          0.022086
     4
          0.072393
     5
          0.236810
     6
          0.020859
     Name: kme, dtype: float64
```



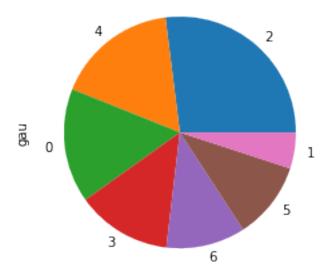
1.7 Gaussian Mixture

```
[23]: cl = 'gau'
agg = GaussianMixture(n_components=k)
X[cl]=Xs[cl]=Xm[cl]=Xt[cl]=Xp[cl]=df[cl] = agg.fit_predict(Xs[varc])
display(df[cl].value_counts(True).sort_index())
df[cl].value_counts().plot(kind='pie')
```

```
0 0.159509
1 0.050307
2 0.269939
3 0.132515
4 0.169325
5 0.107975
6 0.110429
```

Name: gau, dtype: float64

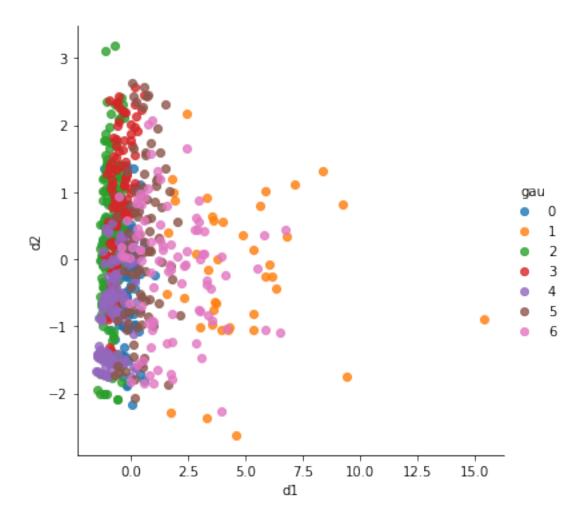
[23]: <AxesSubplot:ylabel='gau'>

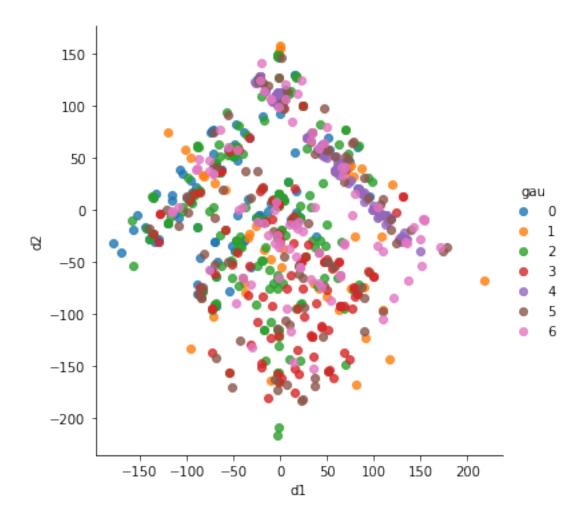


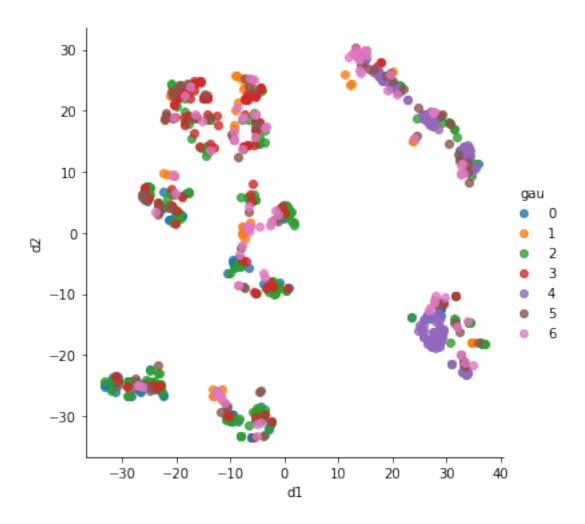
1.8 2D Visualization

```
[24]: sns.lmplot(data=Xp,x='d1',y='d2',fit_reg=False,hue='gau') sns.lmplot(data=Xm,x='d1',y='d2',fit_reg=False,hue='gau') sns.lmplot(data=Xt,x='d1',y='d2',fit_reg=False,hue='gau')
```

[24]: <seaborn.axisgrid.FacetGrid at 0x7f577ab21588>







1.9 Perfilamiento

 $p-value<\alpha$ Son diferentes y por tanto la variable sirve para perfilar

```
[25]:
                               p-value
              variable
         trip_distance
                         2.843500e-109
      0
          PULocationID
      1
                          1.830534e-42
      2
          DOLocationID
                          1.184611e-25
      3
            tip_amount
                          3.332350e-60
          total_amount
                         1.057493e-129
```

```
[26]: sk = SelectKBest(k='all')
      sk.fit(X[varc],X['gau'])
[26]: SelectKBest(k='all')
[27]: best = [v for v,x in zip(varc,sk.get_support()) if x]
      best
[27]: ['trip_distance', 'PULocationID', 'DOLocationID', 'tip_amount', 'total_amount']
     1.10 Examples
[64]: k = 5
      cl = 2
      for id in df.loc[df['gau']==cl].sample(k).DOLocationID:
          print(id)
     140
     142
     246
     224
     238
[69]: i = 5
      cluster = 4
      for id in df.loc[df['gau']==cluster].sample(i).trip_distance:
          print(id)
     0.699999988079071
     1.2999999523162842
     0.4699999988079071
     0.6000000238418579
     0.49000000953674316
        Persistencia
```

```
[71]: import pickle pickle.dump((sc, agg),open('gaussian cluster_midterm.pkl','wb'))
```